Stage-wise 新聞推薦論文詳解

Modeling Stage-wise Evolution of User Interests for News Recommendation
WWW 2026 · 合肥工業大學、合肥綜合性國家科學中心人工智慧研究院 · arXiv:2603.10471 · 程式碼：github.com/yikeJin/SEIN
（在我們的報告中為 Paper B；論文內文沒有替模型命名，只稱為 Ours，程式碼庫名稱為 SEIN）

一、一句話總結

新聞讀者的興趣同時有「長期穩定」和「短期隨事件變動」兩種成分。這篇論文用一張**全域互動圖**學長期偏好，再把點擊依時間切成多個**時段子圖**，用 **LSTM** 捕捉相鄰時段之間的變化、用 **self-attention** 捕捉跨時段的長距離關係，最後把三種表示加總來預測點擊。

二、要解決的問題

2.1 新聞推薦的特殊性

- **時效性強**：新聞很快就失去價值，使用者想看的是最新事件和熱門話題。
- **興趣會隨情境波動**：例如世界盃期間體育新聞暴增、疫情期間健康新聞暴增。
- 因此推薦系統必須同時處理兩件事：
  - **長期興趣**：穩定的閱讀習慣，例如一直關注財經。
  - **短期興趣**：由突發事件帶動、變化很快的興趣。

2.2 既有方法的兩個極端

類型	代表方法	優點	問題
傳統方法	協同過濾（CF）、內容式（CB）	簡單	資料稀疏、冷啟動
神經網路新聞推薦	NPA、NRMS、NAML、DKN	新聞語意表示好	把每次互動視為獨立事件，忽略結構和時間
GCN 圖模型	LightGCN、GNewsRec、DIGAT	能用高階協同訊號	只用**一張靜態全域圖**，舊點擊和新點擊一樣重要，推薦容易過時
時序模型	LSTUR、HieRec、TCCM	能捕捉時間變化	偏重最近行為，容易被短暫熱點牽著走，缺少穩定的協同結構

2.3 核心觀察

使用者–新聞互動天然具有**階段性（stage-wise）結構**：同一時段內的點擊通常反映一致的局部興趣，而跨時段的轉變則顯示興趣如何演變。

三、問題定義

- 使用者集合 U、新聞集合 I。
- 使用者 u 的點擊歷史依時間排序：$H_u = \{(i_1, \psi_1), \ldots, (i_M, \psi_M)\}$，ψ 是時間戳記。
- 任務：給定候選新聞集合 C_u，預測使用者點擊每篇新聞的機率。
- 連續時間被切成離散的時段 $T = \{t_1, \ldots, t_T\}$，例如每週或每兩週一段。

初始表示：

```
使用者：e_u⁰ = P · ID_u                （隨機初始化的可訓練矩陣）
新聞：  e_i⁰ = MLP(LM(Title_i))        （標題經預訓練語言模型編碼後投影到 d 維）
```

附錄說明語言模型用的是 all-MiniLM-L6-v2（384 維），再用單層網路投影到 64 維。使用者沒有文字資訊，只從互動中學習。

四、模型架構

整體由兩大模組組成（對照論文 Figure 1）：

1. **GPM（全域偏好）**：在全域圖 G 上跑 LightGCN，得到長期表示 e_u^g、e_i^g，並用來初始化下一步的時段子圖。
2. **LPM（局部偏好）**：在時段子圖 $G_1 \ldots G_T$ 上建模，分成兩個分支：
   - 短期演化分支：GCN + LSTM
   - 長距離聚合分支：self-attention
3. **預測**：三種使用者表示相加，與新聞表示做內積，再經過 sigmoid。

4.1 圖的建構

- **全域圖** $G = (U \cup I, E)$：只要使用者 u 曾點過新聞 i，就連一條邊。
- **時段子圖** $G_t = (U \cup I, E_t)$：只放第 t 個時段內的點擊。這樣不同時段的訊號不會被混在一起。

4.2 全域偏好建模 GPM（Global Preference Modeling）

在全域圖上跑 **LightGCN**。第 l 層的傳播：

```
e_u^(l+1) = Σ_{i∈N_u} 1/(√|N_u|·√|N_i|) · e_i^(l)
e_i^(l+1) = Σ_{u∈N_i} 1/(√|N_u|·√|N_i|) · e_u^(l)
```

把各層結果加總得到全域表示：

```
e_u^g = Σ_{l=0}^{L} e_u^(l)，  e_i^g = Σ_{l=0}^{L} e_i^(l)
```

雙重角色：

1. 代表使用者的長期、穩定偏好。
2. **作為時段子圖的初始化**。單一時段的互動比全域圖稀疏很多，用全域表示當起點可以提供先驗知識，讓子圖學得更好。

4.3 局部偏好建模 LPM（Local Preference Modeling）

LPM 有兩個互補的分支。

(1) 短期演化分支（Short-term Evolution, STE）

先在每個時段子圖上各跑一次 GCN，並以全域表示初始化：

```
e_u^t, e_i^t = GCN^(t)(G_t; e_u^g, e_i^g)，  t = 1, …, T
```

再用 LSTM 把相鄰時段串起來：

```
ẽ_u^t = LSTM(e_u^t, e_u^(t−1))
ẽ_i^t = LSTM(e_i^t, e_i^(t−1))
```

作用：追蹤興趣一步步的變化，對使用者最近的行為比較敏感。

(2) 長距離聚合分支（Long-range Aggregation, LRA）

LSTM 只看相鄰時段，可能忽略很早以前但仍有影響的興趣，因此再加一個 self-attention 分支。

對每個時段 t，取到該時段為止的所有點擊 $\{i_1, \ldots, i_{m_t}\}$，加上可學習的位置編碼：

```
S_u^t = [ẽ_1^t + p_1, ẽ_2^t + p_2, …, ẽ_{m_t}^t + p_{m_t}]
```

位置編碼 p_j 讓模型分辨點擊的先後順序。接著堆疊 L_a 層帶殘差連接的 self-attention：

```
S_{u,l}^(t) = σ(Self-Att(S_{u,l−1}^(t))) + S_{u,l−1}^(t)
```

最後把所有位置加總，得到時段 t 的累積使用者表示 $\bar{e}_u^t$。

兩個分支的分工

分支	看的範圍	捕捉什麼
短期演化（LSTM）	相鄰時段	對最近變化敏感的局部轉移
長距離聚合（self-attention）	到目前為止的全部點擊	早期興趣和新興趣之間的關係

4.4 預測

把三種使用者表示相加，新聞則用短期表示加全域表示：

```
ê_u^t = ẽ_u^t + ē_u^t + e_u^g
ê_i^t = ẽ_i^t + e_i^g
ŷ_{u,i}^t = sigmoid(ê_u^t · ê_i^t)
```

五、訓練目標

5.1 預測損失

在每個時段內用 binary cross-entropy，每個正樣本配 4 個負樣本：

```
L_t = −Σ_{(u,i)∈D_t} [ y log ŷ + (1 − y) log(1 − ŷ) ]
```

5.2 一致性正則化（Consistency）

用對比學習（InfoNCE）讓同一使用者的時段表示靠近他自己的全域表示，並遠離其他使用者：

```
L_cl^t = -log [ exp(ẽ_u^t · e_u^g / τ) / Σ_j exp(ẽ_u^t · e_j^g / τ) ]
```

作用：避免時段表示偏離全域偏好太遠（語意漂移），把全域和時序兩個視角連起來。

5.3 平滑正則化（Smoothness）

```
L_sl^t = ‖ẽ_u^t − ẽ_u^(t−1)‖²
```

作用：假設興趣是漸進變化的，讓相鄰時段的表示不要跳太大，減少雜訊造成的震盪。

5.4 總損失

```
L = Σ_t λ_t·L_t + λ_cl·L_cl + λ_sl·L_sl + β‖Θ‖²
```

預設 $\lambda_t = 0.1$、$\lambda_{cl} = 0.01$、$\lambda_{sl} = 0.01$，溫度 $\tau = 0.1$。

六、實驗設定

6.1 資料集（Table 1）

資料集	使用者	新聞	點擊	時間跨度	時段切法
Adressa-large（挪威）	3,614,911	81,018	35,244,078	3 個月	每 2 週一段
MIND-large（MSN 英文）	1,000,000	161,013	24,155,470	6 週	每 1 週一段

- **Adressa**：有完整時間戳記。最後一週測試、倒數第二週驗證，其餘訓練。
- **MIND**：第 6 週沒有標籤，排除不用。第 1–4 週只有先後順序、沒有精確時間戳記，所以平均切成 4 個「假時段」用於訓練和驗證；第 5 週整週當測試。

6.2 實作細節

- embedding 維度 64，Adam，學習率 5×10^{-6}，batch size 1024，dropout 0.2
- 依驗證集 AUC early stopping，結果取 5 次平均
- 單張 NVIDIA L20 GPU 即可訓練
- 所有模型的超參數都用相同的 grid search 調整

6.3 Baseline 與指標

- **神經網路新聞推薦**：NPA、NRMS、NAML
- **圖模型**：LightGCN、CNE-SUE
- **時序模型**：TCCM（最相關，也有建時序子圖）、CROWN（WWW 2025，因果推理加上解耦表示）
- **指標**：AUC、MRR、nDCG@5、nDCG@10

七、實驗結果

論文設計了四個研究問題（RQ1–RQ4）。

7.1 RQ1：整體表現（Table 2）

資料集	指標	第二名（CROWN）	本文
Adressa	AUC	0.6553	**0.7993**
	MRR	0.3915	**0.5223**
	nDCG@5	0.4156	**0.4495**
	nDCG@10	0.5283	**0.5327**
MIND	AUC	0.5501	**0.5804**
	MRR	0.3431	**0.4368**
	nDCG@5	0.4156	**0.4429**
	nDCG@10	0.4691	**0.5171**

- 兩個資料集的所有指標都是第一，Adressa 上的 AUC 差距特別大。
- 作者的分析：NPA、NRMS、NAML 有好的語意表示但沒建模時間；LightGCN、CNE-SUE 用靜態圖；TCCM 偏重全域去偏差，沒處理細粒度的偏好變化；CROWN 依賴明確的內容特徵。
- **為什麼 baseline 的 AUC 這麼低**（附錄 A.1.1）：作者用**整個第 5 週**當測試集，比過去研究常用的「只用最後一天」難得多，時間漂移更強，所以沒有時序機制的模型絕對分數偏低，但相對排名仍然穩定。

7.2 RQ2：消融實驗（Table 3，Adressa）

版本	拿掉什麼	AUC	MRR	N@5	N@10
w/o LPM	兩個時序分支都拿掉	0.4880	0.1885	0.1049	0.1416
w/o STE	拿掉 LSTM 分支	0.5109	0.2112	0.2570	0.2713
w/o LRA	拿掉 attention 分支	0.4851	0.2573	0.3120	0.3322
w/o GPM	拿掉全域模組	0.4996	0.4056	0.2812	0.3379
完整模型		**0.7993**	**0.5223**	**0.4495**	**0.5327**

- **拿掉 LPM 掉最多**：只有靜態全域訊號無法捕捉興趣變化。
- **拿掉短期分支**：MRR、nDCG@5 這類對排序前段敏感的指標掉比較多，說明它對快速變化的新聞興趣很重要。
- **拿掉長距離分支**：也明顯下降，表示只追蹤最近變化不夠，還需要較早的歷史脈絡。
- **拿掉 GPM**：除了失去穩定的協同訊號，稀疏的子圖也失去好的初始化。

7.3 RQ3：超參數敏感度

時間窗大小（Figure 2，只在 Adressa 上做，因為 MIND 沒有真正的時間戳記）：比較 1、2、3、4 週。

- **2 週最好**。
- 窗太短：每個子圖太稀疏，表示不穩定。
- 窗太長：細微的興趣變化會被抹平。

損失權重（Figure 3）：

- λ_t 在 0.1 最好；太小時主要任務學不好。
- λ_{cl} 在 0.01 最好；適度對齊能減少語意漂移，又保留對短期變化的彈性。
- λ_{sl} 在 0.01 最好；太小無法維持連續性，太大會過度平滑。

7.4 RQ4：模型能力（Table 4，Adressa）

作者依互動頻率抽樣四組使用者，每組 20,000 人：

- 高互動（平均 377.8 次點擊）、中互動（39.6）、低互動（9.7）、隨機（86.2）

把推薦結果中的新聞分成兩類：**新新聞**（資料集最後一個月發布）和**舊新聞**（最早一個月發布）。比較完整模型和只有 GPM 的版本（w/o LPM）：

- **New% / Historical%**：Top-10 推薦中新、舊新聞的比例
- **NRank / ORank**：新、舊新聞在 Top-10 中的平均排名，數字越小越前面

組別	模型	New%	Historical%	NRank	ORank
高	w/o LPM	0.035	0.036	1.59	1.58
	完整模型	0.014	0.018	0.60	0.82
中	w/o LPM	0.164	0.161	4.31	4.32
	完整模型	0.187	0.145	4.53	3.85
低	w/o LPM	0.159	0.156	4.10	4.12
	完整模型	0.173	0.148	4.09	3.74
隨機	w/o LPM	0.114	0.113	3.38	3.40
	完整模型	0.122	0.102	3.28	3.04

作者的解讀：

- **高互動使用者**：新新聞的排名大幅提前（NRank 1.59 → 0.60）。
- **中、低互動使用者**：新新聞比例提高（例如中互動 16.4% → 18.7%），舊新聞的排名也變好（4.32 → 3.85），在新鮮度和相關性之間取得平衡。
- **隨機組**：新新聞的比例和排名都改善，顯示方法穩健。

八、優點

1. **同時兼顧長期和短期**：全域圖提供穩定性，時段子圖提供時效性。
2. **全域表示當初始化**：有效緩解單一時段資料稀疏的問題，消融實驗也支持這點。
3. **兩個時序分支互補**：LSTM 看局部轉移，self-attention 看長距離依賴。

4. **正則化設計合理**：一致性項防止漂移，平滑項防止震盪。
5. **大規模資料驗證**：兩個資料集都有數千萬筆點擊，而且只需單張 GPU。
6. **評估情境較困難**：用整週當測試集，比只看最後一天更貼近實際的時間漂移。

九、限制與可以討論的地方

1. **Baseline 分數接近隨機**：Adressa 上 NPA、NRMS、NAML、LightGCN、CNE-SUE、TCCM 的 AUC 都在 0.50–0.54，LightGCN 只有 0.4996，低於隨機。作者用「測試期間較長」來解釋，但差距大到值得懷疑 baseline 是否被調到最好，或是評估設定對它們特別不利。
2. **消融結果有可疑之處**：
   - **w/o GPM 那一列和 LightGCN 完全相同**（0.4996 / 0.4056 / 0.2812 / 0.3379）。拿掉全域模組、只留時序模組的版本，數字卻和純 LightGCN 一樣，很可能是誤植。
   - w/o LPM（0.4880）和 w/o LRA（0.4851）的 AUC 都低於 0.5，只拿掉一個分支就從 0.80 掉到比隨機還差，幅度不太合理。
3. **資料集統計前後不一致**：Table 1 寫 Adressa 有 361 萬使用者、8.1 萬篇新聞、3,524 萬次點擊；附錄 A.1 寫約 300 萬使用者、5 萬篇新聞、2,700 萬次點擊。
4. **MIND 沒有真正的時間戳記**：第 1–4 週只能平均切成假時段，削弱了「依時間切段」這個核心設計在 MIND 上的意義。這也可能是 MIND 進步幅度小的原因之一。
5. **固定大小的時間窗**：新聞事件的爆發長短不一，固定兩週不一定適合每個使用者或每個事件。作者在附錄說時間窗只是「粗略的結構先驗」，細節由 LPM 處理，但沒有實驗驗證自適應切段。
6. **RQ4 的解讀不夠清楚**：高互動組中，完整模型的新新聞比例反而從 3.5% 降到 1.4%，論文只強調排名提前，沒有解釋比例下降。而且這些比例都很小，推薦清單大部分是中間月份的新聞。
7. **平滑假設和新聞特性有張力**：論文一方面強調新聞興趣會被突發事件快速改變，另一方面又用平滑正則化假設興趣是漸進變化的。作者在附錄回應說平滑項只是輕度約束（$\lambda_{sl} = 0.01$）。
8. **學習率很小**：5×10^{-6} 對這類模型來說相當小，論文沒有討論收斂速度和訓練時間。
9. **沒有分析計算成本**：每個時段都要跑一次 GCN，加上 self-attention 要看到目前為止的全部點擊，時段數或歷史長度增加時成本會上升，論文沒有給出時間或記憶體分析。

十、和 Paper A（LISRec）的關係（報告時可以提）

	Paper A：LISRec（KDD '26）	Paper B：本文（WWW '26）
挑戰的假設	歷史是**乾淨**的	歷史是**靜態**的
主要訊號	物品文字語意	時間戳記 + 協同圖
圖的角色	每個使用者的物品相似度圖	全域圖 + 各時段的使用者–新聞圖
處理方式	依**語意**篩選歷史	依**時間**切開歷史
會丟掉什麼	丟掉離群的點擊	不丟資料，只是分段
使用方式	可接在任何推薦模型前面的過濾器	端到端模型

兩者可以互補：先用 LISRec 去掉雜訊點擊，再用本文的方法建模興趣隨時間的變化。反過來說，本文假設時段內的點擊是「一致的」，如果時段內混有雜訊，LISRec 的過濾正好可以補強這個假設。